

АНАЛИТИЧЕСКИЙ ОТЧЕТ

по курсовой работе по предмету

“Классическое МО”

Прогнозирование эффективности химических соединений

для разработки противогриппозных препаратов

от студента: “Урамаев. Э.М.”, обучающегося по направлению “Машинное обучение SF”

институт ИИКС

1. Введение и постановка задачи

Данная курсовая работа посвящена построению предиктивных моделей машинного обучения для ускорения процесса разработки противогриппозных лекарственных препаратов. Предоставлены данные о 1000 химических соединениях, описанных молекулярными дескрипторами. Целью курсовой работы стало: научиться предсказывать три ключевых биологических показателя эффективности и безопасности по структуре молекулы.

1.1 Целевые показатели

IC50 полумаксимальная концентрация ингибирования, это концентрация вещества, при которой подавляется 50% вирусной активности. CC50 полумаксимальная цитотоксическая концентрация, это концентрация, при которой погибает 50% здоровых клеток. $SI = CC50 / IC50$ селективный индекс, это интегральный показатель качества препарата: соотношение безопасности и эффективности.

1.2 Постановка задач

В рамках работы решались три задачи регрессии прогнозирование точного числового значения и четыре задачи бинарной классификации:

1. Регрессия IC50, CC50, SI

2. Классификация: IC50 > медианы, соединение малоэффективно?

3. Классификация: CC50 > медианы, соединение относительно безопасно?

4. Классификация: SI > медианы, соединение выше среднего по качеству?

5. Классификация: SI > 8, соединение достигает клинически значимого порога селективности?

2. Разведочный анализ данных EDA

2.1 Описание датасета

Исходный датасет содержал 1 000 строку молекулу и 214 столбцов молекулярных дескрипторов. Все признаки являются числовыми.

2.2 Пропущенные значения

Обнаружено 12 признаков с пропусками на уровне 3%: 4 характеристики экстремальных частичных зарядов и 8 дескрипторов семейства BCUT2D. Систематический характер пропусков около 3% во всех признаках указывает на технический сбой при расчёте, а не на физическое отсутствие данных. Все пропуски заполнены медианой соответствующего признака.

2.3 Распределение целевых переменных

Все три таргета демонстрируют сильно скошенное вправо распределение с длинным правым хвостом: большинство значений IC50 сосредоточено в диапазоне 0 до приблизительно 175 мМ, однако встречаются выбросы до 4000 мМ. Значения CC50 распределены несколько шире. SI практически у нуля с единственным экстремальным значением порядка 16000. Для линейных моделей применено логарифмическое преобразование таргетов: $\log_{10}$ CC50, $\log_{10}$ SI, и отрицательный логарифм $-\log_{10}$ IC50 по аналогии со шкалой pIC50

2.4 Выбросы

Принято обоснованное решение не удалять выбросы по стандартному IQR-методу. Соединение с аномально высоким IC50 это реальная молекула с плохой активностью, а не ошибка измерения. Её удаление было бы статистически некорректно. Вместо этого применена мягкая фильтрация функцией `filter_extreme_values` для шести признаков и для каждого признака вычислялись квантили 0.4 и 0.97, верхняя граница задавалась как $q_{97} + 3 \cdot (q_{97} - q_{40})$, строки с превышением отсеивались. Пары квантилей [0.04, 0.97] использовались только при сравнении вариантов обрезки в EDA, в финальный пайплайн они не вошли.

2.5 Мультиколлинеарность признаков

Анализ матрицы попарных корреляций признаков (около 207-208 столбцов до добавления бинарных меток классификации) выявил значительное количество высокоррелированных пар. Принято решение удалить один из признаков каждой пары с корреляцией выше 0.999 это гарантированные дубликаты, несущие нулевую дополнительную информацию. Порог 0.999 выбран намеренно максимально строгим, чтобы сохранить максимум разнообразия при небольшом объёме выборки. PCA метод главных компонент был осознанно отклонён: несмотря на то что он уменьшил бы размерность, с ней бы пропала бы интерпретируемость признаков.

2.6 Корреляция признаков с таргетами

Корреляционный анализ выявил слабые линейные зависимости между дескрипторами и всеми тремя таргетами. Это заранее предопределило выбор нелинейных ансамблевых методов в качестве основных моделей и позже объясняло закономерно плохое качество линейных регрессий.

2.7 Дублирующие строки

В EDA при проверке `df.duplicated()` отображалось 0 дубликатов, в сохранённом после EDA файле `dataset_after_eda.pkl` остаётся 990 строк, из них 32 полностью совпадающие

записи. В ноутбуках регрессии и классификации перед обучением выполняется `drop_duplicates()`, в результате для моделирования используется 958 уникальных соединений (разбиение train/test 80/20, `random_state=42`).

3. Задачи регрессии

3.1 Методология

Обучение и оценка проводились на 958 уникальных соединениях (после `drop_duplicates`). Для каждого таргета протестировано шесть алгоритмов: линейная, гребневая Ridge и LASSO регрессии, Random Forest, Gradient Boosting и CatBoost. Линейные модели обучались на логарифмированном таргете с предварительным масштабированием признаков `StandardScaler`. Подбор гиперпараметров для ансамблевых моделей выполнялся через `GridSearchCV` с 3-кратной кросс-валидацией, в регрессии оптимизировался RMSE в логарифмической шкале (`scoring=neg_root_mean_squared_error`), итоговое сравнение моделей на тесте - по R², MAE и MAE в реальных единицах. Оценка качества производилась в логарифмическом пространстве MAElog, RMSElog, R² для корректного сравнения моделей, и в реальных миллимолях MAEreal для оценки практического смысла ошибки.

3.2 Регрессия IC50

Финальная модель: CatBoost {`depth=6`, `iterations=300`, `learning_rate=0.03`, `l2_leaf_reg=3`}
Линейные модели показали плохие результаты, зависимость между структурой молекулы и её активностью нелинейна. Среди ансамблей CatBoost с настроенными гиперпараметрами занял первое место: R² = 0.554, MAE = 0.490 в шкале pIC₅₀, ошибка в реальных единицах 196 мМ. Результат так себе, но из контекста задачи, было предположено, что предсказание биологической активности по молекулярным дескрипторам без дополнительных данных принципиально ограничено.

3.3 Регрессия CC50

Финальная модель: Random Forest {`n_estimators=400`, `max_depth=15`, `min_samples_split=3`, `min_samples_leaf=2`}
CC₅₀ оказался несколько легче для прогнозирования, чем IC₅₀. По критерию R² лидировал Gradient Boosting 0.535, но по ошибке в реальных единицах Random Forest MAE real = 270.7 мМ и CatBoost 268.3 мМ оказались точнее. Логарифмическая шкала сглаживает крупные ошибки на молекулах с высокой концентрацией, а обратное преобразование усиливает их. В качестве финальной выбрана модель Random Forest как более устойчивая к выбросам в реальном пространстве.

3.4 Регрессия SI

Финальная модель: CatBoost {`depth=6`, `iterations=300`, `learning_rate=0.03`, `l2_leaf_reg=3`}
Регрессия SI оказалась наиболее сложной задачей, максимально достигнутый R² = 0.25. Это произошло по тому, что SI является производной величиной частным двух предиктируемых показателей, и случайные ошибки в прогнозах IC₅₀ и CC₅₀ могут давать непредсказуемые отклонения SI. Хаотичное распределение SI, выявленное в EDA, подтвердилось на практике. Тем не менее, модель способна улавливать общие паттерны и пригодна для первичного ранжирования соединений.

3.5 Итоговая таблица качества регрессионных моделей

Target	Модель	R ²	MAE log	RMSE log	Примечание
IC50	CatBoost	0.554	0.490	0.623	Лучшая модель
IC50	Gradient Boosting	0.527	0.500	0.641	-
IC50	Random Forest	0.490	0.518	0.665	-
CC50	Gradient Boosting	0.535	0.342	0.480	Лучший R ²
CC50	Random Forest	0.520	0.340	0.488	Лучший MAE real
CC50	CatBoost	0.505	0.342	0.495	-
SI	CatBoost	0.250	0.485	0.612	Производная величина
SI	Gradient Boosting	0.209	-	-	-
SI	Random Forest	0.199	-	-	-

0.527 0.500 0.641 -

IC50 Random Forest

0.490 0.518 0.665 -

CC50 Gradient Boosting

0.535 0.342 0.480 Лучший R²

CC50 Random Forest

0.520 0.340 0.488 Лучший MAE real

CC50 CatBoost 0.505 0.342 0.495 SI CatBoost 0.250 0.485 0.612 Производная величина SI Gradient Boosting

0.209 - - -

SI Random Forest

0.199 - - -

4. Задачи классификации

4.1 Методология

Обучение и оценка проводились на 958 уникальных соединениях (после drop_duplicates). Для всех задач классификации протестированы: Логистическая регрессия со StandardScaler, Random Forest, Gradient Boosting и CatBoost. Логистическая регрессия во всех задачах закономерно уступила ансамблям слабые линейные корреляции, выявленные в EDA, не позволяют построить хорошую линейную границу разделения классов. Подбор гиперпараметров производился через GridSearchCV, оптимизируя ROC-AUC.

4.2 Классификация IC50 > медианы

Финальная модель: Random Forest = ROC-AUC = 0.811, Accuracy = 0.760, Recall = 0.777
Классы сбалансированы 50/50 по определению медианы, поэтому Accuracy корректная метрика. Random Forest после GridSearch показал наилучший ROC-AUC = 0.811, опередив CatBoost и Gradient Boosting оба 0.807. Высокий Recall = 0.777,

модель обнаруживает 78% соединений с IC50 выше медианы то есть корректно откладывает в сторону малоэффективные вещества.

4.3 Классификация CC50 > медианы

Финальная модель: CatBoost = ROC-AUC = 0.872, Accuracy = 0.792, Recall = 0.859 Это лучший результат среди всех задач классификации. Модель идентифицирует потенциально безопасные соединения CC50 > медианы с полнотой 85.9% пропускается лишь 14% веществ, которые заслуживали бы внимания. Высокий Recall снижает риск не увидеть перспективных кандидатов на предварительной обработке.

4.4 Классификация SI > медианы

Финальная модель: CatBoost = ROC-AUC = 0.741, Accuracy = 0.693, Recall около 0.71

Задача	Модель	Accuracy	Precision	Recall	F1	ROC-AUC
IC50 > медиана	Random Forest	0.760	-	0.777	-	0.811
CC50 > медиана	CatBoost	0.792	-	0.859	-	0.872
SI > медиана	CatBoost	0.693	-	0.710	-	0.741
SI > 8	CatBoost, порог 0.326	-	-	0.806	0.624	0.713*

4.5 Классификация SI > 8 бинарный клинически значимый порог

Финальная модель: CatBoost (Balanced) с оптимизированным порогом вероятности 0.326. После GridSearch: ROC-AUC CatBoost = 0.713, Random Forest = 0.718 (лучший по ROC-AUC). При пороге 0.326 для CatBoost: Recall = 0.806, F1 = 0.624 (ROC-AUC от порога не меняется). Это наиболее практически важная задача - выявить соединения с SI > 8, то есть кандидатов на роль реального препарата. Датасет несбалансирован: класс SI > 8 составляет около 35% выборки, что потребовало специального подхода. Применены: стратифицированное разбиение выборки, StratifiedKFold-кросс-валидация, балансировка весов классов class_weight=balanced / auto_class_weights=Balanced. Стандартный порог принятия решений 0.5 давал заниженный Recall. После анализа кривой Precision-Recall для CatBoost найден оптимальный порог 0.326, при котором F1 достигает максимума. Итого при пороге 0.326 модель обнаруживает 80.6% всех соединений с SI > 8, ложноотрицательных стало 13 вместо большего числа при пороге 0.5, F1 вырос до 0.624. В контексте разработки лекарств пропустить перспективный вариант хуже, чем проверить лишнюю молекулу, поэтому выбрана оптимизация Recall при приемлемом F1.

4.6 Итоговая таблица классификации

**ROC-AUC CatBoost после GridSearch, лучший ROC-AUC у RF - 0.718*

Задача	Модель	Accuracy	Precision	Recall	F1	ROC-AUC
IC50 > медиана	Random Forest	0.760	-	0.777	-	0.811
CC50 > медиана	CatBoost	0.792	-	0.859	-	0.872
SI > медиана	CatBoost	0.693	-	0.710	-	0.741
SI > 8	CatBoost, порог 0.326	-	-	0.806	0.624	0.713*

5. Сравнительный анализ и выводы

5.1 Общие закономерности

Во всех семи задачах прослеживается единая закономерность: нелинейные ансамблевые методы Random Forest, Gradient Boosting, CatBoost стабильно превосходят линейные модели. Данные о молекулярных дескрипторах связаны с биологическими эффектами через сложные нелинейные взаимодействия, которые линейные модели принципиально не могут описать.

5.2 Качество по типу задачи

Классификация значительно точнее регрессии это закономерный результат: бинарный ответ выше или ниже медианы улавливается моделями намного лучше, чем точное числовое значение.

5.3 Рекомендации

5.3.1. Использовать Optuna и Bayesian Optimization вместо GridSearchCV 5.3.2. Для CatBoost использовать встроенный механизм ранней остановки, вместо заданного числа итераций. 5.3.3. Применение рекурсивного исключения признаков или отбора по важности деревьев

5.4 Итоговый вывод

В рамках курсовой работы успешно решены семь задач машинного обучения по трём ключевым фармакологическим показателям, для каждой задачи сравнены несколько моделей с подбором гиперпараметров. Проведена предобработка данных: заполнение пропусков, логарифмическое преобразование таргетов, фильтрация экстремумов, удаление мультиколлинеарных признаков, при обучении моделей использовано 958 уникальных соединений после удаления 32 дубликатов из подготовленного датасета. Нелинейные ансамблевые методы победили. Для несбалансированной задачи SI > 8 применена оптимизация порога по кривой PrecisionRecall, что позволило повысить обнаружение перспективных молекул до 80.6%. Таким образом предварительно можно полученные модели использовать для оценки перспективности соединений.